

Zusammenfassung der Übung zu Entropie

Pawel Wocjan*

9. August 2000

Inhaltsverzeichnis

1 Kombinatorische Grundbegriffe	1
1.1 Stirling-Approximation	1
1.2 Binomial- und Multinomialkoeffizienten	5
2 Die Rolle der Entropie bei asymptotischen Abschätzungen	5
2.1 Kompositionsklassen	5
2.2 Herleitung der binären Entropiefunktion	6
2.3 Die q -näre Entropiefunktion	8
3 Entropie als Ungewißheit	9
4 Entropie als Informationsmaß	13

1 Kombinatorische Grundbegriffe

1.1 Stirling-Approximation

Definition 1.1 (Fakultät) Die für alle natürlichen Zahlen $n \in \mathbb{N}$ definierte Funktion $f(n) = n!$, für die gilt: $f(0) = 1$ und für alle n : $f(n+1) = (n+1) \cdot f(n)$, heißt n -Fakultät.

Zur näherungsweisen Berechnung von $n!$ für sehr große Zahlen n benutzt man die *Stirlingsche Formel*.

Satz 1.1 (Stirlingsche Formel) Die Stirlingsche Näherung lautet

$$n! \approx \sqrt{2\pi n} \cdot n^n \cdot e^{-n} \quad \text{bzw.} \quad \ln(n!) \approx \left(n + \frac{1}{2}\right) \ln n - n + \frac{1}{2} \ln(2\pi).$$

*Bei Fragen, Verbesserungsvorschlägen, etc. email an mich: wocjan@ira.uka.de

Beweis: (aus [1]) Zur Herleitung der Stirlingschen Formel, beweisen wir zunächst die folgenden Abschätzungen:

$$\begin{aligned} n! &< e^1 \sqrt{n} \cdot n^n \cdot e^{-n} \\ n! &> e^{\frac{7}{8}} \sqrt{n} \cdot n^n \cdot e^{-n} \end{aligned}$$

Mit einem Trick können wir sie dann benutzen, um die Stirlingsche Formel herzuleiten.

Der Beweis geht über die geometrisch anschauliche Abschätzung von $\int_1^n \ln x dx$ durch eine Obersumme O und eine Untersumme U . Es gilt

$$\int_1^n \ln x dx = n \ln n - n + 1.$$

Anhand des folgenden Bildes (selber überlegen) wird die Untersumme U entwickelt. Wir approximieren den Flächeninhalt durch die Trapezregel:

$$\int_1^n \ln x dx \geq \sum_{i=1}^{n-1} \frac{\ln i + \ln(i+1)}{2}$$

$$\begin{aligned} U &= \frac{1}{2} \ln n + \frac{1}{2} \ln 1 + \sum_{i=2}^{n-1} \ln i \\ &= \ln(n-1)! + \frac{1}{2} \ln n \\ &= \ln n! - \frac{1}{2} \ln n \end{aligned}$$

Wir haben also $\ln n! - \frac{1}{2} \ln n < n \ln n - n + 1$. Wir lösen nach $\ln n!$ auf und erhalten so

$$\ln n! < 1 + \frac{1}{2} \ln n + n \ln n - n.$$

Wir wenden die Exponentialfunktion auf diese Ungleichung und erhalten so die *obere Schranke*

$$n! < n^n e^{-n} \sqrt{n} e \leq n!.$$

Die Berechnung für die Obersumme O ist etwas aufwendiger. Das folgende Bild macht sie anschaulich. Wir unterscheiden drei Fälle.

- Der Flächeninhalt über $[1, 1.5]$ wird durch den des Dreiecks überboten, dessen Hypotenuse die Steigung 1 hat. Dieses Dreieck hat den Flächeninhalt $O_1 = \frac{1}{8}$.
- Über den Intervallen $[i - \frac{1}{2}, i + \frac{1}{2}]$ für $i = 2, \dots, n-1$ bilden wir Trapeze, deren Mittellinie die Länge $\ln i$ hat und deren Oberseite die Tangentensteigung der Logarithmuskurve als Steigung hat. Der Flächeninhalt ist Höhe (hier die Intervalllänge) mal Mittellinie gleich $\ln i$. Alle Trapeze haben also insgesamt den Flächeninhalt $O_2 = \sum_{i=2}^{n-1} \ln i = \ln(n-1)!$.

- Über $[n - \frac{1}{2}, n]$ bilden wir das Rechteck, dessen Seitenlänge $\ln n$ ist. Es hat den Flächeninhalt $O_3 = \frac{1}{2} \ln n$.

So ergibt sich insgesamt für die Obersumme

$$\begin{aligned} O &= O_1 + O_2 + O_3 \\ &= \frac{1}{8} + \ln n! - \frac{1}{2} \ln n \end{aligned}$$

und damit

$$\frac{1}{8} + \frac{1}{2} \ln n + n \ln n < \ln n!,$$

wenn wir nach $\ln n!$ auflösen. Wir wenden die Exponentialfunktion auf diese Ungleichung und erhalten so die *untere Schranke*

$$n! > n^n e^{-n} \sqrt{n} e^{7/8}.$$

Nach der Ungleichung ist $n!$ also $n^n e^{-n} \sqrt{n} C$, wobei C zwischen $e^{7/8}$ und e liegt. Wir beweisen noch, daß

$$\lim_{n \rightarrow \infty} C = \sqrt{2\pi}$$

gilt.

Um diesen Koeffizienten C für $n \rightarrow \infty$ zu berechnen, wenden wir einen Trick an und betrachten dazu das Integral

$$I_k = \int_0^{\pi/2} \cos^k x dx$$

für $k \geq 0$. Die trigonometrische Identität $\cos^2 x = 1 - \sin^2 x$ liefert für $k \geq 2$

$$\begin{aligned} I_k &= \int_0^{\pi/2} \cos^{k-2} x (1 - \sin^2 x) dx \\ &= I_{k-2} + \int_0^{\pi/2} \cos^{k-2} x (-\sin x) \sin x dx \\ &= I_{k-2} + \frac{1}{k-1} \int_0^{\pi/2} (\cos^{k-1} x)' \cdot \sin x dx. \end{aligned}$$

Partielle Integration ergibt nun

$$\begin{aligned} I_k &= I_{k-2} + \frac{\cos^{k-1} x}{k-1} \sin x \Big|_0^{\pi/2} - \frac{1}{k-1} \int_0^{\pi/2} \cos^{k-1} x \cos x dx \\ &= I_{k-2} - \frac{1}{k-1} I_k. \end{aligned}$$

Bei der Auflösung nach I_k erhalten wir die Rekurrenzformel

$$I_k = \frac{k-1}{k} I_{k-2}$$

für $k \geq 2$. Man kann leicht zeigen, daß

$$\begin{aligned} I_1 &= 1 \\ I_0 &= \frac{\pi}{2} \end{aligned}$$

gilt.

Wir bemerken nun, daß wegen $\cos x \leq 1$ ($x \in [0, \frac{\pi}{2}]$) gilt

$$I_{2k-1} > I_{2k} > I_{2k+1}.$$

Wir teilen diese Ungleichung durch I_{2k-1} und erhalten

$$1 > \frac{I_{2k}}{I_{2k-1}} > \frac{I_{2k+1}}{I_{2k-1}}.$$

Wir ersetzen sukzessive die Terme mit Hilfe der Rekurrenzformel und erhalten

$$1 > 2k \left[\frac{2k-1}{2k} \frac{2k-3}{2k-2} \cdots \frac{3}{2} \right]^2 \frac{\pi}{2} > \frac{2k}{2k+1}$$

Wir können den Zähler in der eckigen Klammer gleich $(2k)!$ machen, indem wir den Bruch mit dem dem Nenner erweitern. Wir verwenden

$$2k(2k-2)(2k-4) \cdots = 2^k k!$$

und erhalten

$$1 > \pi k \left[\frac{(2k)!}{2^k \cdot (k!) \cdot 2^k \cdot (k!)} \right]^2 > \frac{2k}{2k+1}.$$

Wir ziehen nun aus jedem Glied die positive Quadratwurzel

$$1 > \sqrt{\pi k} \left[\frac{(2k)!}{(k!)^2 \cdot 2^{2k}} \right] > \sqrt{1 - \frac{1}{2k+1}}$$

Schließlich setzen wir die Näherung

$$n! = n^n e^{-n} \sqrt{n} C$$

in diese Ungleichung für jede Fakultät ein und erhalten

$$1 > \sqrt{\pi k} \left[\frac{(2k)^{2k} e^{-2k} \sqrt{2k} C}{2^{2k} k^k e^{-k} \sqrt{k} C k^k e^{-k} \sqrt{k} C} \right] > \sqrt{1 - \frac{1}{2k+1}}$$

Deshalb gilt für $k \rightarrow \infty$

$$C \rightarrow \sqrt{2\pi}.$$

Damit haben wir die Stirlingsche Formel bewiesen

$$n \approx \sqrt{2\pi n} \cdot n^n \cdot e^{-n}.$$

Das Verhältnis des Stirlingschen Nährungswertes zum wahren Wert ist selbst für kleine Werte bemerkenswert gut. Die Nährung ist so beschaffen, daß sie für $n \rightarrow \infty$ *relative* exakt ist, die Differenz jedoch *nicht* Null erreicht.

Wenn dies ungewohnt erscheint, so betrachte man die beiden Funktionen

$$\begin{aligned} f(n) &= n + \sqrt{n} \\ g(n) &= n \end{aligned}$$

Der Limes des Verhältnisses ist

$$\frac{f(n)}{g(n)} = \frac{n + \sqrt{n}}{n} = 1 + \frac{1}{\sqrt{n}} \rightarrow 1.$$

Die Differenz beträgt jedoch

$$f(n) - g(n) = \sqrt{n} \rightarrow \infty.$$

Die Approximation $n \approx \sqrt{2\pi n} \cdot n^n \cdot e^{-n}$ ist schon für kleine Werte von n genau, aber es gibt noch schärfere Abschätzungen

$$\sqrt{2\pi n} \cdot n^n \cdot e^{-n} \cdot e^{\frac{1}{12n+1}} < n! < \sqrt{2\pi n} \cdot n^n \cdot e^{-n} \cdot e^{\frac{1}{12n}},$$

deren Beweis in [2] gefunden werden kann.

1.2 Binomial- und Multinomialkoeffizienten

Definition 1.2 (Binomialkoeffizient) Die für alle natürlichen Zahlen n und k ($0 \leq k \leq n$) definierte Funktion

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

heißt *Binomialkoeffizient*.

Die Werte des Binomialkoeffizienten können sukzessiv aus dem *Pascalschen Dreieck* ermittelt werden.

Definition 1.3 (Multinomialkoeffizient) Die für alle natürlichen Zahlen n und alle q -Tupel $(k_1, k_2, \dots, k_q)$, für die $\sum_{i=1}^q k_i = n$ gilt, erklärte Funktion

$$\binom{n}{k_1, k_2, \dots, k_q} = \frac{n!}{k_1! k_2! \dots k_q!}$$

heißt *Multinomialkoeffizient*.

Anmerkung 1.1 Der Binomialkoeffizient $\binom{n}{k}$ ist demnach ein spezieller Multinomialkoeffizient $\binom{n}{k_1, k_2}$ mit $k_1 = k$ und $k_2 = n - k$.

2 Die Rolle der Entropie bei asymptotischen Abschätzungen

Wir führen den Begriff der Entropie ein und klären ihre Bedeutung bei asymptotischen Abschätzungen.

2.1 Kompositionsklassen

Mit $\mathcal{A}_q$ bezeichnen wir ein endliches *Alphabet*, d.h. eine endliche Menge

$$\mathcal{A}_q = \{a_1, a_2, \dots, a_q\},$$

die q verschiedene Symbole $a_1, a_2, \dots, a_q$ enthält. Wir betrachten Sequenzen der Länge n über $\mathcal{A}_q$. Die Anzahl der Sequenzen wächst exponentiell mit der Länge n .

Üblicherweise werden die Sequenzen *lexikographisch* geordnet, wobei

$$a_1 < a_2 < \dots < a_q$$

gilt. Wir betrachten jetzt eine andere Ordnung, die später eine zentrale Rolle spielen wird. Dazu definieren wir für jede Sequenz über dem Alphabet $\mathcal{A}_q$ der Länge n das q -Tupel

$$\vec{k} = (k_1, k_2, \dots, k_q) \text{ mit } \sum_{i=1}^n k_i = n,$$

wobei k_i angibt, wie oft das Symbol a_i in der Sequenz vorkommt (die Reihenfolge ist dabei egal). Eine *Kompositionsklasse* besteht aus Sequenzen, deren $\vec{k}$'s übereinstimmen. Die Anordnung der Sequenzen innerhalb einer Kompositionsklasse nicht entscheidend; wir werden sie lexikographisch anordnen. Wir ordnen die Kompositionsklassen lexikographisch bezüglich ihrer zugehörigen $\vec{k}$ -Vektoren an. Für gegebene q und n ist eine Kompositionsklasse durch ihr zugehöriges q -Tupel $\vec{k}$ eindeutig bestimmt.

Definition 2.1 Die Anzahl der verschiedenen Kompositionsklassen für gegebene q und n wird mit $\mathcal{K}(q, n)$ bezeichnet.

Satz 2.1 Die Anzahl der verschiedenen Kompositionsklassen $\mathcal{K}(q, n)$ ist die Anzahl der verschiedenen Kombinationen mit Wiederholung von n Elementen der Ordnung q und damit

$$\mathcal{K}(q, n) = A(\tilde{C}_q^n) = \binom{n+q-1}{q}.$$

Definition 2.2 Die Anzahl der Sequenzen in der Kompositionsklasse mit dem zugehörigen Tupel heißt Multiplizität $M(\vec{k})$ der Kompositionsklasse.

Satz 2.2 Die Multiplizität $M(\vec{k})$ der Kompositionsklasse mit dem zugehörigen Tupel $\vec{k} = (k_1, k_2, \dots, k_q)$ ist durch den Multinomialkoeffizienten

$$M(\vec{k}) = \binom{n}{k_1, k_2, \dots, k_q},$$

gegeben, wobei $n = \sum_{i=1}^q k_i$.

2.2 Herleitung der binären Entropiefunktion

Wir betrachten hier den Fall $q = 2$ und bezeichnen die beiden Symbole mit A und B . Wir werden die binäre Entropiefunktion herleiten und ihre Bedeutung bei asymptotischen Abschätzungen erklären. Diese Ergebnisse werden im nächsten Abschnitt für $q > 2$ verallgemeinert.

Wir wollen das asymptotische Verhalten der Grössen von Kompositionsklassen für $n \rightarrow \infty$ untersuchen, wobei die relative Häufigkeit der A 's gleich bleiben soll. Wir betrachten also eine Folge von Kompositionsklassen mit den Paaren $\vec{k} = (k_A, k_B)$, wobei $k_A = \lambda n$ und $k_B = (1 - \lambda)n$. Wir wissen, daß die Grössen durch die Binomialkoeffizienten $\binom{n}{\lambda n}$ gegeben sind. Wir benutzen die Approximationen

$$\sqrt{2\pi n} \cdot n^n \cdot e^{-n} \cdot e^{\frac{1}{12n+1}} < n! < \sqrt{2\pi n} \cdot n^n \cdot e^{-n} \cdot e^{\frac{1}{12n}},$$

um Abschätzungen für die Binomialkoeffizienten zu bekommen.

Als untere Schranke für den Binomialkoeffizienten

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

erhalten wir

$$\frac{1}{\sqrt{2\pi n \lambda(1-\lambda)}} \cdot n^n \cdot k^{-k} \cdot (n-k)^{-(n-k)} \cdot e^{\frac{1}{12n+1} - \frac{1}{12k} - \frac{1}{12(n-k)}},$$

indem wir für den Zähler $n!$ die obige Unterschranke und für die Faktoren $k!$ und $(n-k)!$ im Nenner die Oberschranke verwenden. Der Logarithmus des Terms $n^n \cdot k^{-k} \cdot (n-k)^{-(n-k)}$ ist

$$n \log_2 n - k \log_2 k - (n-k) \log_2 (n-k).$$

Wenn wir $n \log_2 n$ in die Summe $k \log_2 n + (n-k) \log_2 n$ aufspalten und die Logarithmenregeln anwenden, vereinfacht sich der Ausdruck zu

$$k \log \frac{n}{k} + (n-k) \log_2 (n-k).$$

Wir verwenden jetzt, daß die relative Häufigkeit $\underline{k}_A = \lambda$ fest bleibt, d.h. $k = k_A = \lambda n$, und damit

$$n \left(\lambda \log_2 \frac{1}{\lambda} + (1-\lambda) \log_2 \frac{1}{1-\lambda} \right) = n H_2(\lambda),$$

2 DIE ROLLE DER ENTROPIE BEI ASYMPTOTISCHEN ABSCHÄTZUNGEN

wobei

$$H_2(\lambda) = -\lambda \log_2 \lambda - (1 - \lambda) \log_2(1 - \lambda)$$

die *binäre Entropiefunktion* bezeichnet. Die *Unterschranke* für den Binominalkoeffizienten ist also

$$\frac{1}{\sqrt{2\pi n\lambda(1-\lambda)}} \cdot 2^{nH_2(\lambda)} \cdot e^{\frac{1}{12n+1} - \frac{1}{12\lambda n} - \frac{1}{12(1-\lambda)n}} \leq \binom{n}{\lambda n}.$$

Die *Oberschranke* wird analog hergeleitet. Sie ist

$$\binom{n}{\lambda n} \leq \frac{1}{\sqrt{2\pi n\lambda(1-\lambda)}} \cdot 2^{nH_2(\lambda)} \cdot e^{\frac{1}{12n} - \frac{1}{12\lambda n+1} - \frac{1}{12(1-\lambda)n+1}}.$$

Wir können die Oberschranke auch als

$$2^{nH_2(\lambda)} \cdot 2^{-\frac{1}{2} \log_2(2\pi n\lambda(1-\lambda)) + \log_2 e \cdot \left(\frac{1}{12n} - \frac{1}{12\lambda n+1} - \frac{1}{12(1-\lambda)n+1}\right)}$$

schreiben, indem wir den Logarithmus von der Wurzel ziehen und ihn im Exponenten schreiben. Der Term

$$\frac{1}{2} \log_2(2\pi n\lambda(1-\lambda)) - \log_2 e \cdot \left(\frac{1}{12n} - \frac{1}{12\lambda n+1} - \frac{1}{12(1-\lambda)n+1}\right)$$

kann in der Funktionsklasse $o(n)$ versteckt werden, wobei

$$o(n) := \left\{ f : \mathbf{N} \rightarrow \mathbf{R}, \lim_{n \rightarrow \infty} \frac{f(n)}{n} = 0 \right\}.$$

Damit haben wir den folgenden Satz bewiesen:

Satz 2.3 (Die binäre Entropiefunktion) *Es gilt:*

$$\binom{n}{\lambda n} = 2^{nH_2(\lambda) - o(n)}$$

Genauer:

$$2^{nH_2(\lambda) - f(n)} \leq \binom{n}{\lambda n} \leq 2^{nH_2(\lambda) - g(n)},$$

wobei

$$\begin{aligned} f(n) &= \frac{1}{2} \log_2(2\pi n\lambda(1-\lambda)) - \log_2 e \cdot \left(\frac{1}{12n+1} - \frac{1}{12\lambda n} - \frac{1}{12(1-\lambda)n}\right) \\ g(n) &= \frac{1}{2} \log_2(2\pi n\lambda(1-\lambda)) - \log_2 e \cdot \left(\frac{1}{12n} - \frac{1}{12\lambda n+1} - \frac{1}{12(1-\lambda)n+1}\right) \end{aligned}$$

2.3 Die q -näre Entropiefunktion

Definition 2.3 (Die q -näre Entropiefunktion) Es sei $\vec{k} = (k_1, k_2, \dots, k_q)$ mit $k_i \geq 0$ und $\sum_{i=1}^q k_i = 1$. Die Funktion

$$H_q(\vec{k}) = \sum_{i=1}^q k_i \log k_i$$

heißt die q -näre Entropiefunktion. Mit dem q -Tupel $\vec{k}$ werden die relativen Häufigkeiten der Alphabetsymbole $a_1, a_2, \dots, a_q$ festgelegt.

Ähnlich im binären Fall kann die q -näre Entropiefunktion heranziehen, um Multiplizitäten von Kompositionsklassen zu abzuschätzen:

$$M(\vec{k}) = \binom{n}{k_1, k_2, \dots, k_q} \approx 2^{nH_q(\vec{k})}.$$

3 Entropie als Ungewißheit

Wir haben im vorhergehenden Abschnitt die Entropie hergeleitet und ihre Bedeutung bei asymptotischen Abschätzungen erläutert. Jetzt wollen wir zeigen, daß die Entropie auch ein Maß für Ungewißheit darstellt. Dieser Zugang wird üblicherweise in der Informationstheorie benutzt. Betrachten wir einige Beispiele, die verdeutlichen, was eigentlich Ungewißheit bedeutet:

- Der Ausgang eines Rennens zwischen zwei ebenbürtigen Pferden ist nicht so ungewiß wie der eines Rennens zwischen sechs ebenbürtigen Pferden.
- Beim Roulette ist das Ergebnis ungewisser als bei einem Würfelwurf.
- Wird ein unverfälschter Würfel geworfen, ist das Ergebnis ungewisser, als wenn ein einseitig belasteter Würfel geworfen wird, bei dem die Wahrscheinlichkeit $\frac{1}{10}$ besteht, eine der Zahlen 1 bis 5 zu würfeln, und $\frac{1}{2}$, eine 6 zu würfeln.

Wir fordern axiomatisch einige Eigenschaften, die man sinnvollerweise von der Ungewißheit erwartet und zeigen dann, daß die Entropiefunktion die einzige Funktion ist, die diese Eigenschaften erfüllt. Deswegen stellt die Entropie ein Maß für die Ungewißheit dar.

Eigenschaften der Ungewissheit

E1 H ist eine symmetrische Funktion der Argumente $p_1, p_2, \dots, p_q$, d.h. für jede Permutation π von $1, 2, \dots, q$ gilt:

$$H(p_1, p_2, \dots, p_q) = H(p_{\pi(1)}, p_{\pi(2)}, \dots, p_{\pi(q)}).$$

Es kommt lediglich auf die Wahrscheinlichkeiten an und nicht auf deren Reihenfolge.

E2 H ist eine nichtnegative Funktion, d.h. es gilt:

$$H(p_1, \dots, p_q) \geq 0.$$

H nimmt den Wert Null an, genau dann wenn

$$\exists i : p_i = 1.$$

Die Ungewissheit ist eine von Natur aus positive Größe und nimmt nur dann den Wert Null an, wenn keine Zufälligkeit vorhanden ist.

E3 H hat ein Maximum, genau dann wenn

$$p_1 = p_2 = \dots = p_q = \frac{1}{q},$$

d.h.

$$\max_{p_1, \dots, p_q} H(p_1, \dots, p_q) = H\left(\frac{1}{q}, \dots, \frac{1}{q}\right).$$

Der Ausgang eines Rennens ist höchst ungewiß, wenn alle Pferde ebenbürtig sind.

E4 Es gilt:

$$H\left(\frac{1}{q}, \dots, \frac{1}{q}\right) \leq H\left(\frac{1}{q+1}, \dots, \frac{1}{q+1}\right)$$

Der Ausgang eines Rennens mit zwei ebenbürtigen Pferden ist weniger ungewiß als der eines Rennens mit drei ebenbürtigen Pferden.

E5 Es gilt:

$$H\left(\frac{1}{q_1 q_2}, \dots, \frac{1}{q_1 q_2}\right) = H\left(\frac{1}{q_1}, \dots, \frac{1}{q_1}\right) + H\left(\frac{1}{q_2}, \dots, \frac{1}{q_2}\right)$$

Die Gesamtungewißheit der Ausgänge von zwei unabhängigen Pferderennen, an denen jeweils ebenbürtige Pferde teilnehmen, besteht aus der Summe der Ungewißheiten der einzelnen Pferderennen.

E6 Es gilt:

$$H\left(\frac{1}{q}, \dots, \frac{1}{q}, 0\right) = H\left(\frac{1}{q}, \dots, \frac{1}{q}\right)$$

Der Ausgang eines Rennens, an dem zusätzlich ein Holzpferd teilnimmt, bleibt gleich ungewiß.

E7 H sollte eine stetige Funktion ihrer Argumente sein, d.h. bei kleinen Änderungen der Wahrscheinlichkeiten sollte sich die Ungewißheit nicht wesentlich ändern.

E8 Es seien $p^{(1)} = p_1^{(1)} + \dots + p_{q_1}^{(1)}$ und $p^{(2)} = p_1^{(2)} + \dots + p_{q_2}^{(2)}$. Dann läßt sich bei $p^{(1)} + p^{(2)} = 1$

$$H(p_1^{(1)}, \dots, p_{q_1}^{(1)}, p_1^{(2)}, \dots, p_{q_2}^{(2)})$$

wie folgt zerlegen

$$H(p^{(1)}, p^{(2)}) + p^{(1)} H\left(\frac{p_1^{(1)}}{p^{(1)}}, \dots, \frac{p_{q_1}^{(1)}}{p^{(1)}}\right) + p^{(2)} H\left(\frac{p_1^{(2)}}{p^{(2)}}, \dots, \frac{p_{q_2}^{(2)}}{p^{(2)}}\right).$$

Die obige Situation tritt beispielsweise bei einem Pferderennen auf, an dem zusammen q_1 schwarze Pferde und q_2 weisse Pferde teilnehmen. Dabei ist $p_i^{(1)}$ die Wahrscheinlichkeit, daß das i -te schwarze Pferd gewinnt, und $p_j^{(2)}$ die Wahrscheinlichkeit, daß das j -te weisse Pferd gewinnt. Folglich sind $p^{(1)}$ und $p^{(2)}$ die Wahrscheinlichkeiten, daß ein schwarzes bzw. ein weisses Pferd gewinnt.

Die Gesamtungewißheit ergibt sich nun aus Summe der Ungewißheit, ob ein schwarzes oder weisses Pferd gewinnt, sowie den gewichteten Ungewißheiten unter der Voraussetzung, daß der Gewinner ein schwarzes bzw. weisses Pferd ist.

Das folgende Theorem zeigt, daß die Entropiefunktion die einzige Funktion ist, die die Eigenschaften E1-E8 der Ungewißheit erfüllt.

Theorem 3.1 (Entropie als Maß für Ungewißheit) *Es sei $H(p_1, \dots, p_q)$ eine Funktion, die für alle Zahlen $p_1, \dots, p_q \in \mathbb{R}$ mit*

$$p_i \geq 0 \text{ und } \sum_{i=1}^q p_i = 1$$

definiert ist. Wenn H die Eigenschaften E1 bis E8 erfüllen soll, dann gilt

$$H(p_1, \dots, p_q) = -\lambda \sum_{i=1}^q p_i \log_b p_i.$$

Hierbei ist $\lambda \in \mathbb{R}$ eine beliebige positive Konstante, und die Summe wird über diejenigen i gebildet, für die $p_i > 0$ gilt.

Beweis: Wir definieren

$$g(q) = H\left(\frac{1}{q}, \frac{1}{q}, \dots, \frac{1}{q}\right)$$

für alle $q \in \mathbb{N}$. Nach E5

$$H\left(\frac{1}{q_1 q_2}, \dots, \frac{1}{q_1 q_2}\right) = H\left(\frac{1}{q_1}, \dots, \frac{1}{q_1}\right) + H\left(\frac{1}{q_2}, \dots, \frac{1}{q_2}\right)$$

gilt (setze $q_1 = q_2 = q$)

$$g(q^2) = g(q) + g(q) = 2g(q)$$

und damit

$$g(q^k) = k \cdot g(q)$$

für $k \in \mathbb{N}$. Nach E4

$$H\left(\frac{1}{q}, \dots, \frac{1}{q}\right) \leq H\left(\frac{1}{q+1}, \dots, \frac{1}{q+1}\right)$$

gilt

$$g(q) \leq g(q+1)$$

und damit sieht man, daß g eine monoton steigende Funktion, d.h.

$$g(q_1) \leq g(q_2)$$

für $q_1 \leq q_2$ und $q_1, q_2 \in \mathbb{N}$. Funktionen, die diese beiden Eigenschaften erfüllen, sind die elementaren Funktionen

$$g(q) = A \log_b(q)$$

wobei $A \in \mathbb{R}^+$ eine Konstante ist und der Logarithmus zu einer beliebigen Basis $b > 1$ genommen wird.

Als nächstes betrachten wir die Eigenschaft E8: Für $p^{(1)} = p_1^{(1)} + \dots + p_{q_1}^{(1)}$ und $p^{(2)} = p_1^{(2)} + \dots + p_{q_2}^{(2)}$ läßt sich

$$H\left(p_1^{(1)}, \dots, p_{q_1}^{(1)}, p_1^{(2)}, \dots, p_{q_2}^{(2)}\right)$$

in

$$H\left(p^{(1)}, p^{(2)}\right) + p^{(1)} \cdot H\left(\frac{p_1^{(1)}}{p^{(1)}}, \dots, \frac{p_{q_1}^{(1)}}{p^{(1)}}\right) + p^{(2)} \cdot H\left(\frac{p_1^{(2)}}{p^{(2)}}, \dots, \frac{p_{q_2}^{(2)}}{p^{(2)}}\right)$$

zerlegen. Für $q = q_1 + q_2$ und

$$p_1^{(1)} = \dots = p_{q_1}^{(1)} = \frac{1}{q}$$

$$p_1^{(2)} = \dots = p_{q_2}^{(2)} = \frac{1}{q}$$

haben wir $p^{(1)} = \frac{q_1}{q}$ und $p^{(2)} = \frac{q_2}{q} = \frac{q-q_1}{q}$. Nach E8 läßt sich $g(q)$ als

$$H\left(\frac{q_1}{q}, \frac{q-q_1}{q}\right) + \underbrace{\frac{q_1}{q} H\left(\frac{1}{q_1}, \dots, \frac{1}{q_1}\right)}_{g(q_1)} + \underbrace{\frac{q-q_1}{q} H\left(\frac{1}{q-q_1}, \dots, \frac{1}{q-q_1}\right)}_{g(q-q_1)}$$

schreiben. Wir haben also

$$g(q) = H\left(\frac{q_1}{q}, \frac{q - q_1}{q}\right) + \frac{q_1}{q}g(q_1) + \frac{q - q_1}{q}g(q - q_1).$$

Wenn wir jetzt $g(x) = A \log x$ ausnutzen, so erhalten wir mit elementaren Umformungen

$$\begin{aligned} H\left(\frac{q_1}{q}, \frac{q - q_1}{q}\right) &= A \left(\log q - \frac{q_1}{q} \log q_1 - \frac{q - q_1}{q} \log(q - q_1) \right) \\ &= -A \left(\log q_1^{\frac{q_1}{q}} + \log(q - q_1)^{\frac{q - q_1}{q}} - \log q \right) \\ &= -A \log \frac{q_1^{\frac{q_1}{q}} \cdot (q - q_1)^{\frac{q - q_1}{q}}}{q} \\ &= -A \log \left(\left(\frac{q_1}{q} \right)^{\frac{q_1}{q}} \cdot \left(\frac{q - q_1}{q} \right)^{\frac{q - q_1}{q}} \right) \\ &= -A \log \left(\frac{q_1}{q} \log_2 \left(\frac{q_1}{q} \right) + \frac{q - q_1}{q} \log_2 \left(\frac{q - q_1}{q} \right) \right) \\ &= -A (p \log p + (1 - p) \log(p - 1)) \\ &= H(p, 1 - p) \end{aligned}$$

Damit haben wir für $q = 2$ die Lösung. Wir vermuten nun, daß allgemein

$$H(p_1, p_2, \dots, p_q) = -A \sum_{i=1}^q p_i \log p_i \quad (1)$$

gilt. Wir beweisen dies mit vollständiger Induktion. Die Induktionsverankerung ist die Lösung für $q = 2$. Die Induktionsannahme ist, daß die obige Gleichung bis zu einem gewissen $q \in \mathbb{N}$ gilt. Wir machen den Induktionsschluß auf $q + 1$ und betrachten dazu

$$H(p_1, p_2, \dots, p_q, p_{q+1}).$$

Wir setzen $p_i^{(1)} = p_i$ für $i = 1, \dots, q$, $p^{(1)} = \sum_{i=1}^q p_i^{(1)}$ und $p^{(2)} = p_1^{(2)} = p_{q+1}$ und wenden wieder E8 an. Mit elementaren Umformungen erhalten wir dann

$$\begin{aligned} &H(p_1, \dots, p_q, p_{q+1}) \\ &= H(p^{(1)}, p^{(2)}) + p^{(1)} \cdot H\left(\frac{p_1^{(1)}}{p^{(1)}}, \dots, \frac{p_q^{(1)}}{p^{(1)}}\right) + p^{(2)} \cdot H\left(\frac{p_1^{(2)}}{p^{(2)}}\right) \\ &= H(p^{(1)}, p^{(2)}) + p^{(1)} \cdot H\left(\frac{p_1}{p^{(1)}}, \dots, \frac{p_q}{p^{(1)}}\right) + p^{(2)} \cdot \underbrace{H(1)}_{=0} \\ &= -A \left(p^{(1)} \log p^{(1)} + p^{(2)} \log p^{(2)} \right) - p^{(1)} A \sum_{i=1}^q \frac{p_i}{p^{(1)}} \log \frac{p_i}{p^{(1)}} \end{aligned}$$

$$\begin{aligned}
&= -A \left(p^{(1)} \log p^{(1)} + p^{(2)} \log p^{(2)} \right) - A \sum_{i=1}^q p_i \log p_i + A p^{(1)} \log p^{(1)} \\
&= -A \sum_{i=1}^q p_i \log p_i
\end{aligned}$$

Damit ist die Behauptung für alle $q \in \mathbb{N}$ bewiesen.

4 Entropie als Informationsmaß

Es sei $\Omega = \{\omega_1, \dots, \omega_n\}$ die Menge der Elementarereignisse und $\mathcal{P} = (p_1, \dots, p_q)$ ein Wahrscheinlichkeitsmaß auf Ω . Die zugehörige Entropie ist

$$H(\mathcal{P}) = H(p_1, \dots, p_q) = - \sum_{i=1}^q p_i \log p_i \quad \left[\frac{\text{bit}}{\text{EE}} \right].$$

Wir wollen zeigen, daß die Entropie der Mittelwert der Selbstinformation der Elementarereignisse ist. Dazu definieren wir ein Maß für die Information, die ein Elementarereignis trägt. Betrachten wir die Zufallsvariable

$$X = -\log p.$$

Zu jedem Elementarereignis ω_i gehört der Wert x_i der Zufallsvariablen

$$x_k = -\log P(\omega_i) = -\log p_i.$$

Die Größe $-\log p_i$ wird oft als *Selbstinformation*, das zu dem Elementarereignis ω_i gehört, bezeichnet:

$$I(\omega_i) = -\log p_i.$$

Die Einheit der Information wird als *Bit* bezeichnet, wobei 1 Bit der der Information entspricht, die mit dem Auswählen von zwei gleichwahrscheinlichen Elementarereignissen ($p_1, p_2 = \frac{1}{2}$) assoziiert ist. In diesem Fall haben wir

$$I(\omega_1) = I(\omega_2) = -\log \frac{1}{2} = 1 \text{ bit}.$$

Die Auswahl zwischen zwei gleichwahrscheinlichen Elementarereignissen benötigt 1 bit an Information. Wenn Ω in 2^n gleichwahrscheinliche Ereignisse partitioniert wird, dann beträgt die Selbstinformation eines Elementarereignisses

$$I(\omega_i) = -\log p_i = -\log 2^{-n} = n \text{ bits}$$

Die Selbstinformation ist eine nichtnegative Größe:

$$I(\omega_i) = -\log p_i \geq 0.$$

Gleichheit ergibt sich nur bei einem sicheren Ereignis; in dem Wissen des Auftretens dieses Ereignisses liegt kein Informationsgehalt.

Wenn $I(\omega_i)$ den Informationsgehalt angibt, der mit dem Auftreten des Elementarereignisses verbunden ist, so gibt die Entropie

$$H(p_1, p_2, \dots, p_n) = - \sum_{i=1}^n p_i \log p_i = \overline{I(\omega_i)}$$

den mittleren Informationsgehalt an.

Literatur

- [1] R. W. Hamming, *Coding and information theory*, Englewood Cliffs, NJ : Prentice-Hall, 1980.
- [2] U. Krengel, *Einführung in die Wahrscheinlichkeitstheorie und Statistik*, vieweg studium, 1991.